

Relatório do Trabalho Final de Tópicos em IA

- **Disciplina:** DC/CCN072, Tópicos em Inteligência Artificial (UFPI, 2026.1)
- **Professor:** Raimundo Santos Moura
- **Grupo 2:** Francisco Cosme Monteiro Xavier, Heitor Andrade Moura, Isaac Augusto Santana Brito e João Pedro Monteiro da Silva Barros
- **Livro base:** *Build a Large Language Model (From Scratch)* (Sebastian Raschka, 2024)

Este notebook consolida os **sete notebooks** do trabalho final: a fundação de avaliação (**01**), as seis questões (**02** a **06**), com objetivo, método e resultado (antes/depois) de cada uma, e a avaliação comparativa final (**07**). A análise crítica aprofundada, gráfico a gráfico, está em `07_final_eval.ipynb`.

Objetivo do trabalho

- Aplicar, sobre um mesmo modelo e um mesmo domínio, **seis técnicas distintas** de adaptação e avaliação de LLMs vistas na disciplina (pré-treino contínuo, SFT/LoRA, destilação, RAG, guardrails).
- Medir cada técnica com **métricas próprias** e mostrar, com números, **o que cada uma resolve**, em vez de tratar "melhorar o modelo" como um objetivo único.

Configuração comum

- **Modelo:** Qwen3-4B na rodada oficial (professor da destilação; aluno Qwen3-0.6B; sonda de esquecimento em Qwen3-1.7B). Troca de `MODEL_ID` numa linha.
- **Dados:** **DOM-PI**, o Diário Oficial dos Municípios do Piauí (`gutoportelaa/dom-pi-corpus-2025`) e **docentesDC** (`vickminari/docentesDC`, 13.762 docs rotulados por professor), ambos no Hugging Face.
- **Infra:** Google Colab com **GPU T4** grátis (QLoRA 4-bit para caber em 16 GB; treino em float32 por compatibilidade do GradScaler na T4).
- **Benchmarks próprios:** 30 perguntas abertas + 20 MCQ (DOM-PI) e 100 MCQ (destilação: ~80 conceituais + 20 factuais). Distratores das MCQ são valores/nomes reais de outros atos do DOM-PI.

Baseline (fundação comum: Qwen3-4B cru)

Medido em `01_eval_baseline.ipynb` antes de qualquer técnica:

Métrica	Valor	Leitura
Perplexidade no domínio	10,33	ponto de partida da adaptação (Q1)
Similaridade nas abertas	0,831	alta mesmo errando: satura (ver Limitações)
Acerto factual nas abertas	0/30	o modelo não tem os fatos locais , prova de ausência de contaminação

O acerto factual zero do modelo cru é a evidência-chave do trabalho: todo ganho factual mostrado adiante vem das técnicas (RAG, SFT), não de conhecimento decorado no pré-treino do Qwen.

Mapa dos notebooks (1 a 7) por questão

Notebook	Papel	Questão	Status
01_eval_baseline.ipynb	Fundação: harness de avaliação + o "antes" comum	todas	executado (4B)
02_rag.ipynb	RAG: recuperação + geração (e5 + FAISS)	Q5	executado (4B)
03_qlora_sft.ipynb	SFT com QLoRA 4-bit via TRL (atribuição de autoria)	Q2 e Q3	executado (4B)
04_continued_pretrain.ipynb	Pré-treino contínuo com LoRA (próximo token)	Q1	executado (4B)
05_distillation.ipynb	Destilação: professor 4B para aluno 0.6B (dados sintéticos)	Q4	executado
06_guardrails.ipynb	Guardrails: filtros + máscara de PII (sem treino)	Q6	executado
07_final_eval.ipynb	Avaliação comparativa final: IC 95%, LLM-juiz, sonda de esquecimento	todas	executado

As seções a seguir percorrem os resultados por questão (Q1 a Q6, cada uma no seu notebook) e fecham com a **avaliação comparativa do 07**, que cruza todos os modelos nos mesmos benchmarks.

Q1: Pré-treino contínuo (DOM-PI)

- **Objetivo:** adaptar o modelo ao domínio dos Diários Oficiais e medir o ganho de fluência.
- **Método:** treino contínuo (previsão do próximo token) com LoRA sobre o corpus DOM-PI, em blocos de 1024 tokens (*packing*); métricas ANTES e DEPOIS em conjunto *held-out* (docs-fonte do benchmark **excluídos** do treino, como controle de contaminação).
- **Notebook:** 04_continued_pretrain.ipynb.

Resultado (rodada oficial, Qwen3-4B, 800 docs):

Métrica	Antes	Depois	Leitura
Perplexidade (held-out)	7,05	3,77 (queda de 47%)	adaptação forte ao domínio
Acurácia de token	0,612	0,695	idem
Acurácia MCQ	0,333	0,500	fluência ajuda um pouco, mas fato local continua sendo papel do RAG

- **Sonda de esquecimento** (no 07, em 1.7B): a perplexidade **fora do domínio não sobe** após o pré-treino: adaptação **sem esquecimento catastrófico**.

Q2 / Q3: Fine-tuning supervisionado com QLoRA

- **Objetivo:** ensinar o modelo a responder no formato instrução-resposta sobre o docentesDC. Como o dataset é um corpus (documento + nome_professor), a tarefa é **atribuição de autoria** (do documento para o professor; 19 professores distintos no conjunto usado).
- **Método:** SFT com **QLoRA 4-bit** via TRL: apenas **1,48%** dos parâmetros treinados (33M de 2,24B), o que permite ajustar um 4B numa T4 grátis. 1000 pares de treino com **deduplicação** treino/avaliação (controle de contaminação); held-out de 25 documentos.
- **Q2 e Q3:** mesmo pipeline; o Q3 destaca o eixo LoRA/QLoRA (memória versus qualidade).
- **Notebook:** 03_qlora_sft.ipynb.

Resultado (rodada oficial, Qwen3-4B):

Métrica	Antes	Depois	Referências
Atribuição (geração livre)	0,00	0,56	acaso $1/19 = 0,053$; baseline de classe 0,24
Perplexidade da resposta correta (no 07)	2796	7,05	queda de cerca de 400 vezes: o SFT "gravou" a tarefa
Cloze por loss média (secundária)	0,04	0,04	subestima: viés de comprimento em nomes compostos

- **Lição metodológica (resultado em si):** a primeira avaliação (cloze por loss média) dava ~0,04 e sugeria "tarefa não-aprendível". Era **artefato da métrica**. A geração livre + match normalizado, confirmada por inspeção item-a-item (respostas_q3.json), mostra o aprendizado real: **a escolha da métrica pode inverter a conclusão**.

Q4: Destilação de conhecimento

- **Objetivo:** transferir a capacidade de um modelo grande (professor) para um menor (aluno) via dados sintéticos (destilação *black-box*).
- **Método:** o professor **Qwen3-4B** responde prompts conceituais; o aluno **Qwen3-0.6B** faz SFT nessas respostas; por fim compara-se aluno antes/depois e contra o professor. Treino e avaliação usam **metades disjuntas** do benchmark conceitual (controle de vazamento); 20 factuais como controle.

- **Notebook:** 05_distillation.ipynb.

Resultado (rodada oficial):

MCQ	Professor 4B	Aluno 0.6B antes	Aluno 0.6B depois
Conceitual (disjunto)	0,732	0,659	0,659
Factual (controle)	0,250	0,200	0,300

- **Leitura:** o aluno de 0.6B já captura ~**90% da competência conceitual** do professor de 4B a **1/7 do tamanho**: o valor da destilação aqui é *compressão*. O factual fica em torno do acaso (0,25) para todos: destilação transfere **como responder**, não **fato local** (papel do RAG, Q5).

Q5: RAG (Retrieval-Augmented Generation)

- **Objetivo:** melhorar respostas factuais fornecendo ao modelo trechos recuperados dos Diários.
- **Método:** *chunk* do corpus (619 docs: fontes do benchmark + distratores), embeddings (multilingual-e5-small), índice **FAISS**, recuperação top-4 e geração com o contexto. Avaliação declarada **open-book** (o índice contém os docs-fonte por construção).
- **Notebook:** 02_rag.ipynb; avaliação estendida no 07 (benchmark MCQ maior + LLM-juiz).

Resultado (rodada oficial, Qwen3-4B, 30 abertas):

Métrica	Sem-RAG	Com-RAG	Leitura
Acerto factual (abertas)	0,000	0,433	o ganho real: fato vem da recuperação
Acurácia MCQ (8 itens, nb 02)	0,250 (= acaso)	0,875	idem
Acurácia MCQ (20 itens, 07)	0,250	0,500	benchmark maior/mais difícil (conjuntos distintos)
Nota do LLM-juiz de 0 a 5 (07)	1,83	3,30	terceira métrica independente concordando
Similaridade (e5)	0,831	0,856	quase não move: satura (métrica secundária)

- A distribuição das notas do juiz é **bimodal com RAG** (0 ou 5): quando o *retriever* acha o documento certo a resposta é perfeita; quando falha, zero. O gargalo passa a ser o **recall da recuperação**, não o modelo.

Q6: Guardrails (segurança e confiabilidade)

- **Objetivo:** camada de controle que bloqueia pedidos perigosos, detecta injeção de prompt, recusa fora de escopo e mascara PII, **sem treinar** o modelo (moderação multi-camada: entrada, filtros, LLM e máscara na saída, nessa ordem).
- **Notebook:** 06_guardrails.ipynb.

Resultado (41 casos de teste):

Filtro	Acertos	Taxa
Bloqueio de conteúdo perigoso	18/20	0,90
Deteção de injeção/jailbreak	7/7	1,00
Escopo (on-topic e fora)	8/8	1,00
Máscara de PII (CPF, e-mail, telefone)	6/6	1,00
Proteção geral	39/41	0,951

- Os 2 casos que passaram são frases perigosas **parafraseadas** sem as palavras-chave dos filtros, limite conhecido de regras/keywords (ver Limitações).

Avaliação comparativa final (07_final_eval.ipynb)

O 07 cruza os 6 modelos (bases + adapters publicados no HF) nos mesmos benchmarks, com IC 95% de Wilson, e adiciona as análises transversais: sonda de esquecimento, perplexidade da resposta, LLM-juiz e a crítica das métricas. É o notebook-relatório avaliado, com um gráfico por célula e análise crítica de cada um.

MCQ conceitual por modelo (IC 95%; acaso = 0,25):

Modelo	Conceitual	IC 95%
0.6B base	0,659	[0,51 a 0,78]
0.6B + destilação	0,683	[0,53 a 0,80]
1.7B base	0,683	[0,53 a 0,80]
1.7B + pré-treino	0,732	[0,58 a 0,84]
4B base	0,732	[0,58 a 0,84]
4B + SFT	0,610	[0,46 a 0,74]

Leituras principais:

- Todos **bem acima do acaso**; os IC **se sobrepõem**: diferenças pequenas (ex.: 4B+SFT abaixo do 4B base, sugerindo custo de especialização) são **tendência, não fato estatístico** com este n .
- Sonda de esquecimento (Q1)**: do 1.7B base para o 1.7B + pré-treino, a perplexidade no domínio vai de 10,46 para 8,64 e **fora do domínio de 7,94 para 6,64** (não sobe): adaptação sem esquecimento.
- Perplexidade da resposta (Q2/Q3)**: de 2796 para 7,05 após o SFT, o sinal mais forte do trabalho.
- LLM-juiz (Q5)**: nota média de 1,83 para 3,30 com RAG; distribuição **bimodal** com RAG (0 ou 5) localiza o gargalo no *recall* do retriever.

- **Crítica de métrica:** o gráfico de saturação mostra respostas factualmente erradas com similaridade ~0,85, o que justifica a escolha de factual/MCQ/juiz como métricas principais.

Tabela consolidada de resultados (rodada oficial)

Q	Técnica	Métrica principal	Antes	Depois
Q1	Pré-treino contínuo	Perplexidade no domínio	7,05	3,77 (queda de 47%)
Q2/Q3	SFT (QLoRA, 1,48% params)	Atribuição de autoria (geração livre)	0,00	0,56 (acaso 0,05; baseline 0,24)
Q2/Q3	SFT (QLoRA)	Perplexidade da resposta correta	2796	7,05
Q4	Destilação 4B para 0.6B	MCQ conceitual do aluno	0,659	0,659 (cerca de 90% do professor 0,732)
Q5	RAG	Acerto factual (abertas)	0,000	0,433
Q5	RAG	Nota do LLM-juiz (0 a 5)	1,83	3,30
Q6	Guardrails	Proteção geral (41 casos)	-	0,951

Todos os números são de execução real na T4 (notebooks com outputs preservados em notebooks/; JSONs por questão em results/). Acurácias no 07 acompanham **IC 95% de Wilson**.

Conclusões

Cada técnica resolve uma coisa diferente. O ponto central do trabalho não é "qual técnica é a melhor", e sim *o que cada uma muda*:

- **Pré-treino contínuo (Q1)** dá **fluência no domínio**: perplexidade com queda de 47% (de 7,05 para 3,77), **sem esquecimento catastrófico** (a perplexidade fora do domínio não sobe).
- **SFT/QLoRA (Q2/Q3)** ensina uma **tarefa específica**: atribuição de autoria de 0,00 para 0,56 treinando só 1,48% dos parâmetros. E deixa a lição metodológica: **a métrica errada (cloze por loss média) invertia a conclusão**; geração livre + inspeção item-a-item é a leitura correta.
- **Destilação (Q4)** faz **compressão**: o aluno 0.6B retém ~90% da competência conceitual do professor 4B a 1/7 do tamanho. Não transfere fato local (controle no acaso), nem deveria.
- **RAG (Q5)** resolve **fato pontual**: acerto factual de 0 para 0,43 e MCQ de 0,25 para 0,875 sem tocar nos pesos. Três métricas independentes (factual, MCQ, LLM-juiz) concordam.
- **Guardrails (Q6)** dão **segurança sem treino**: 95% de proteção com filtros determinísticos.

Em conjunto: **fluência e formato vêm de adaptar o modelo (pré-treino/SFT); fatos verificáveis vêm de recuperar o documento certo (RAG); segurança vem de camadas externas (guardrails)**. Otimizar uma métrica única esconde essa divisão de trabalho.

Limitações e trabalhos futuros

Infraestrutura (Colab T4 grátis):

- Treinos enxutos (poucos passos/época única) e modelos em **4-bit**, única forma de caber um 4B em 16 GB. Com mais GPU, mais passos e dados aprofundariam os ganhos.

Métricas e benchmarks:

- A **similaridade semântica satura** (resposta errada no mesmo tema pontua ~0,85); por isso as conclusões se apoiam em **acerto factual, MCQ e LLM-juiz**; a similaridade fica como diagnóstico.
- O **cloze por loss média subestimou** a atribuição (viés de comprimento), corrigido para geração livre + match normalizado, com inspeção item-a-item persistida (`respostas_q3.json`).
- Benchmarks pequenos (dezenas de itens) resultam em **IC 95% largos** no 07; diferenças pequenas entre modelos não são estatisticamente significativas e são reportadas como tendência.
- O **LLM-juiz é da mesma família** do gerador (Qwen3-4B); um juiz externo/maior seria mais isento.

Por questão:

- **Q4:** o aluno 0.6B já chega competente no benchmark conceitual (0,659), pouca margem para o ganho da destilação aparecer; um benchmark conceitual mais difícil evidenciaria a transferência.
- **Q5:** os erros remanescentes com RAG são **falhas de recall do retriever** (distribuição bimodal das notas do juiz); melhorar embedding/top-k/re-ranking é a evolução natural.
- **Q6:** filtros por regra/keyword são frágeis a paráfrase (2/20 escaparam); em produção, um **classificador** (ex.: Llama Guard) substituiria as regras.

Trabalhos futuros: benchmark curado maior; juiz externo (8B+); re-ranking no RAG; classificador de segurança no Q6; destilação com benchmark conceitual mais difícil e dados sintéticos via RAG.

Reprodutibilidade

Como rodar (Google Colab):

- Abra o notebook da questão no Colab e selecione **Runtime > GPU T4**.
- Ajuste o seletor **MODE** no topo: `"smoke"` (rápido, valida o pipeline em 1.7B) ou `"oficial"` (resultado de entrega em 4B, 4-bit). É a única linha a trocar entre protótipo e rodada final.
- **Run all.** Os notebooks que treinam pedem login no Hugging Face (token `write`) e fazem `push_to_hub`.

Reaproveitamento (evita re-treino): os notebooks 03/04/05 têm um interruptor `RETRAIN`. Com `RETRAIN=False` (padrão), se o adapter já existe no HF eles **carregam e pulam o treino**, o que permite re-rodar só as células de avaliação/gráficos sem esperar. `RETRAIN=True` treina do zero e publica.

Avaliação consolidada: o `07_final_eval` carrega todos os modelos do HF (não treina), avalia com intervalos de confiança e gera os gráficos + análise crítica. Ele **tolera adapter ausente** (pula o que faltar e segue).

Ordem sugerida: `01_eval_baseline` (mede o "antes"), depois as técnicas (`02` a `06`) e por fim `07_final_eval` (consolida).

Modelos publicados (Hugging Face, usuário `heitor-am`):

- `heitor-am/qwen3-1.7b-dompi-pretrain`: adapter LoRA do pré-treino contínuo (Q1; sonda 1.7B).
- `heitor-am/qwen3-4b-dompi-sft`: adapter QLoRA do SFT (Q2/Q3).
- `heitor-am/qwen3-0.6b-dompi-distill`: aluno destilado (Q4).
- Carregar de volta: `PeftModel.from_pretrained(base, "heitor-am/qwen3-4b-dompi-sft")`.

Artefatos no repositório:

- `notebooks/`: os 8 notebooks **executados** (outputs preservados como prova de execução).
- `results/`: `results_qN.json` por questão, `results_final.json` (consolidado do `07`), respostas por item para verificação humana (`respostas_.json`, `baseline.json`) e figuras `fig_.png`.
- `src/`: fontes `.py` dos notebooks + conversor `nbgen.py`.
- `docs/`: resultados consolidados (`RESULTS.md`), resumo de apresentação (`STATUS.md`) e PDFs.