



Adaptação de LLMs na prática

Seis técnicas sobre o mesmo modelo e o mesmo domínio:
Qwen3 nos Diários Oficiais do Piauí

Francisco Cosme Monteiro Xavier Heitor Andrade Moura Isaac Augusto Santana Brito João
Pedro Monteiro da Silva Barros

Grupo 2 Prof. Raimundo Santos Moura

Julho de 2026

Departamento de Computação, Universidade Federal do Piauí
DC/CCN072, Tópicos em Inteligência Artificial

O modelo parece saber

Perguntamos ao Qwen3-4B, sem nenhuma adaptação, 30 perguntas sobre atos reais dos Diários Oficiais dos Municípios do Piauí:

similaridade semântica

0,831

a resposta “soa” certa

acerto factual

0/30

nenhum fato local correto

O modelo fala como um Diário Oficial, mas **não sabe nenhum fato local**.

Duas perguntas guiam o trabalho

1. Como **dar conhecimento** de um domínio a um LLM?

pré-treino contínuo, SFT, destilação, RAG, guardrails

2. Como **medir de verdade** o que mudou?

métricas que saturam, métricas que enganam, intervalos de confiança

Tese central: cada técnica resolve uma coisa diferente. Otimizar “o modelo” como objetivo único esconde essa divisão de trabalho.

Configuração comum

- **Modelo:** Qwen3-4B na rodada oficial (aluno da destilação: 0.6B; sonda de esquecimento: 1.7B)
- **Dados:** DOM-PI (corpus dos Diários Oficiais) e docentesDC (13.762 docs rotulados por professor)
- **Infra:** Google Colab com GPU T4 **grátis**; QLoRA 4-bit para caber um 4B em 16 GB
- **Benchmarks próprios:** 30 abertas + 20 MCQ (DOM-PI) e 100 MCQ (destilação), com distratores reais do corpus

Adapters publicados no Hugging Face; notebooks executados com outputs preservados como prova de execução.

Seis questões, sete notebooks

	Técnica	O que ela entrega
Q1	Pré-treino contínuo (LoRA)	fluência no domínio
Q2/Q3	SFT com QLoRA	uma tarefa específica
Q4	Destilação 4B / 0.6B	compressão de competência
Q5	RAG (e5 + FAISS)	fatos verificáveis
Q6	Guardrails	segurança sem treino

O notebook 01 mede o “antes” comum; o 07 cruza todos os modelos nos mesmos benchmarks, com IC 95%.

Q1: pré-treino contínuo adapta sem esquecer

Treino de próximo token com LoRA sobre 800 documentos do DOM-PI:

	Antes	Depois	
Perplexidade no domínio	7,05	3,77	queda de 47%
Acurácia de token	0,612	0,695	

Sonda de esquecimento (1.7B): a perplexidade **fora do domínio não sobe** (de 7,94 para 6,64). Adaptação **sem esquecimento catastrófico**.

Q2/Q3: SFT com QLoRA, e um resultado que assustou

Tarefa: **atribuição de autoria** no docentesDC (documento $\Rightarrow$ um de 19 professores).
Treinamos só **1,48%** dos parâmetros (33M de 2,24B).

primeira avaliação (cloze por loss média):

0,04 antes **0,04** depois

A loss de treino caiu de 2,64 para 1,97... então **quem estava errado: o treino ou a métrica?**

A métrica estava errada

Deixando o modelo gerar o nome (e comparando normalizado):

antes do SFT

0,00

depois do SFT

0,56

acaso = 0,05; baseline de classe = 0,24


O cloze por loss média tem **viés de comprimento** e ranqueia mal nomes compostos: subestimava um modelo que acerta a maioria.

A escolha da métrica pode inverter a conclusão.

Q2/Q3: a prova mais forte

Perplexidade que o modelo atribui à **resposta correta**:

Q2/Q3 — Perplexidade da resposta correta (menor = melhor)



de **2796**
para **7,05**

queda de cerca de 400 vezes:
o SFT “gravou” a tarefa no modelo


Q4: destilação é compressão

O professor (4B) responde prompts conceituais; o aluno (0.6B) faz SFT nessas respostas. Avaliação em metade **disjunta** do benchmark (sem vazamento).

MCQ	Professor 4B	Aluno antes	Aluno depois
Conceitual	0,732	0,659	0,659
Factual (controle)	0,250	0,200	0,300

O aluno retém **cerca de 90% da competência conceitual** com **1/7 do tamanho**. O factual fica no acaso para todos: destilação transfere **como responder**, não **fato local**.

Q5: RAG entrega o que falta, o fato




Três métricas independentes concordam:

- MCQ: 0,25 para **0,875** (notebook 02)
- acerto factual: 0 para 0,433
- LLM-juiz (0 a 5): 1,83 para **3,30**

O zero sem RAG é também a prova de ausência de contaminação: o fato local não estava decorado.

Q5: onde o RAG ainda falha



Com RAG a distribuição vira **bimodal**:
0 ou 5.

- recuperou o documento certo: resposta nota 5
- o *retriever* falhou: resposta zero

O gargalo passa a ser o **recall da recuperação**, não o modelo gerador.


Q6: segurança sem treinar nada

Moderação multi-camada: entrada, filtros, LLM e máscara de PII na saída, nessa ordem.

Filtro	Acertos	Taxa
Bloqueio de conteúdo perigoso	18/20	0,90
Deteção de injeção/jailbreak	7/7	1,00
Escopo (dentro e fora do domínio)	8/8	1,00
Máscara de PII (CPF, e-mail, telefone)	6/6	1,00
Proteção geral	39/41	0,951

Os 2 escapes são paráfrases sem as palavras-chave: limite conhecido de filtros por regra (em produção, um classificador como Llama Guard).

Todos os modelos, o mesmo benchmark, IC 95%



- todos **bem acima do acaso** (0,25)
- os intervalos **se sobrepõem**: diferenças pequenas são tendência, não fato estatístico
- 4B+SFT abaixo do 4B base sugere o custo da especialização

Síntese: cada técnica resolve uma coisa

	Resultado	Leitura
Pré-treino	perplexidade de 7,05 para 3,77	fluência, sem esquecer
SFT/QLoRA	atribuição de 0,00 para 0,56	tarefa específica
Destilação	90% do professor com 1/7	compressão
RAG	factual de 0 para 0,433	fato verificável
Guardrails	proteção 0,951	segurança externa

Fluência e formato vêm de adaptar o modelo;
fatos vêm da recuperação; segurança vem de camadas externas.

- **Benchmarks pequenos** (dezenas de itens): IC 95% largos; reportamos incerteza em vez de superinterpretar
- **LLM-juiz da mesma família** do gerador (Qwen3-4B); mitigado por três métricas concordantes
- **RAG open-book**: o índice garante o documento-fonte; mede o limite superior, não recall em corpus aberto
- **Treinos enxutos** (T4 grátis, poucos passos): demonstração honesta, não estado da arte


**o modelo que “soava” certo tirava zero em fato;
medir bem importa tanto quanto treinar bem**

$$0 \rightarrow 0,433$$

acerto factual com RAG, a técnica certa para o problema certo

Obrigado! Perguntas?

Backup: por que a similaridade não serve como métrica



Respostas **factualmente erradas** pontuam similaridade próxima de 0,85: a métrica **satura** no mesmo tema.

Exemplo real: pergunta sobre a Portaria 790 de Teresina respondida com “São João del Rei/MG” teve similaridade 0,80.

Backup: controles de contaminação por questão

- **Q1:** documentos-fonte do benchmark **excluídos** do corpus de treino
- **Q2/Q3:** deduplicação de quase-duplicatas treino/avaliação; baseline de classe majoritária reportado
- **Q4:** treino e avaliação em metades **disjuntas** do benchmark conceitual
- **Q5:** avaliação declarada **open-book**
- **Evidência global:** o modelo cru tirou 0/30 no acerto factual; os fatos locais não estavam no pré-treino

Backup: o viés do cloze em 30 segundos

O cloze ranqueia candidatos pela **loss média por token** do nome dado o documento:

- nomes compostos longos diluem a evidência em mais tokens
- tokens genéricos (“DE”, “DA”, “SILVA”) puxam a média
- resultado: candidato errado e curto vence o certo e longo

Diagnóstico confirmado por inspeção item a item (respostas_q3.json): em geração livre o modelo escreve o nome correto na maioria dos documentos do held-out.

Backup: sonda de esquecimento completa (1.7B)

Perplexidade	1.7B base	1.7B + pré-treino
Domínio (DOM-PI)	10,46	8,64
Fora do domínio (docentesDC)	7,94	6,64

A perplexidade fora do domínio **também cai**: nenhum sinal de esquecimento catastrófico neste regime de treino (LoRA, poucos passos, base congelado em 4-bit).

Backup: tabela consolidada completa

Q	Métrica	Antes	Depois	Referência
Q1	Perplexidade domínio	7,05	3,77	
Q1	Acurácia MCQ	0,333	0,500	acaso 0,25
Q2/Q3	Atribuição (geração)	0,00	0,56	acaso 0,05; maj. 0,24
Q2/Q3	PPL da resposta	2796	7,05	
Q4	MCQ conceitual (aluno)	0,659	0,659	professor 0,732
Q5	Acerto factual	0,000	0,433	
Q5	MCQ (nb 02 / nb 07)	0,250	0,875 / 0,500	benchmarks distintos
Q5	LLM-juiz (0 a 5)	1,83	3,30	
Q6	Proteção geral	–	0,951	41 casos

Backup: reprodutibilidade

- Repositório público: `github.com/heitor-am/llm-adaptation-lab`
notebooks executados com outputs preservados, resultados por item, figuras e relatório
- Adapters no Hugging Face (usuário `heitor-am`): `qwen3-1.7b-dompi-pretrain`, `qwen3-4b-dompi-sft`, `qwen3-0.6b-dompi-distill`
- Interruptor RETRAIN: com `False`, os notebooks carregam o adapter publicado e pulam o treino
- Tudo roda em Colab T4 grátis; seletor `MODE` troca entre protótipo (1.7B) e rodada oficial (4B)