

Adaptação de LLMs na prática

Seis técnicas sobre o mesmo modelo e o mesmo domínio:
Qwen3 nos Diários Oficiais do Piauí

Francisco Cosme Monteiro Xavier Heitor Andrade Moura
Isaac Augusto Santana Brito João Pedro Monteiro da Silva Barros

Departamento de Computação, Universidade Federal do Piauí
DC/CCN072, Tópicos em Inteligência Artificial
Prof. Raimundo Santos Moura

Julho de 2026



O modelo parece saber

Perguntamos ao Qwen3-4B, sem nenhuma adaptação, 30 perguntas sobre atos reais dos Diários Oficiais dos Municípios do Piauí:

similaridade semântica

0,831

a resposta “soa” certa

acerto factual

0/30

nenhum fato local correto

O modelo fala como um Diário Oficial, mas **não sabe nenhum fato local**.

Duas perguntas guiam o trabalho

- 1 Como **dar conhecimento** de um domínio a um LLM?
pré-treino contínuo, SFT, destilação, RAG, guardrails
- 2 Como **medir de verdade** o que mudou?
métricas que saturam, métricas que enganam, intervalos de confiança

Tese central: cada técnica resolve uma coisa diferente. Otimizar “o modelo” como objetivo único esconde essa divisão de trabalho.

Configuração comum

- **Modelo:** Qwen3-4B na rodada oficial (aluno da destilação: 0.6B; sonda de esquecimento: 1.7B)
- **Dados:** DOM-PI (corpus dos Diários Oficiais) e docentesDC (13.762 docs rotulados por professor)
- **Infra:** Google Colab com GPU T4 **grátis**; QLoRA 4-bit para caber um 4B em 16 GB
- **Benchmarks próprios:** 30 abertas + 20 MCQ (DOM-PI) e 100 MCQ (destilação), com distratores reais do corpus

Adapters publicados no Hugging Face; notebooks executados com outputs preservados como prova de execução.

Seis questões, sete notebooks

	Técnica	O que ela entrega
Q1	Pré-treino contínuo (LoRA)	fluência no domínio
Q2/Q3	SFT com QLoRA	uma tarefa específica
Q4	Destilação 4B / 0.6B	compressão de competência
Q5	RAG (e5 + FAISS)	fatos verificáveis
Q6	Guardrails	segurança sem treino

O notebook 01 mede o “antes” comum; o 07 cruza todos os modelos nos mesmos benchmarks, com IC 95%.

Q1: pré-treino contínuo adapta sem esquecer

Treino de próximo token com LoRA sobre 800 documentos do DOM-PI:

	Antes	Depois	
Perplexidade no domínio	7,05	3,77	queda de 47%
Acurácia de token	0,612	0,695	

Sonda de esquecimento (1.7B): a perplexidade **fora do domínio não sobe** (de 7,94 para 6,64). Adaptação **sem esquecimento catastrófico**.

Q2/Q3: SFT com QLoRA, e um resultado que assustou

Tarefa: **atribuição de autoria** no docentesDC (documento $\Rightarrow$ um de 19 professores).
Treinamos só **1,48%** dos parâmetros (33M de 2,24B).

primeira avaliação (cloze por loss média):

0,04 antes **0,04** depois

A loss de treino caiu de 2,64 para 1,97... então **quem estava errado: o treino ou a métrica?**

A métrica estava errada

Deixando o modelo **gerar** o nome (e comparando normalizado):

antes do SFT

0,00

depois do SFT

0,56

acaso = 0,05; baseline de classe = 0,24


O cloze por loss média tem **viés de comprimento** e ranqueia mal nomes compostos: subestimava um modelo que acerta a maioria.

A escolha da métrica pode inverter a conclusão.

Q2/Q3: a prova mais forte

Perplexidade que o modelo atribui à **resposta correta**:

Q2/Q3 — Perplexidade da resposta correta (menor = melhor)



de **2796**
para **7,05**

queda de cerca de 400 vezes:
o SFT “gravou” a tarefa no modelo


Q4: destilação é compressão

O professor (4B) responde prompts conceituais; o aluno (0.6B) faz SFT nessas respostas. Avaliação em metade **disjunta** do benchmark (sem vazamento).

MCQ	Professor 4B	Aluno antes	Aluno depois
Conceitual	0,732	0,659	0,659
Factual (controle)	0,250	0,200	0,300

O aluno retém **cerca de 90% da competência conceitual** com **1/7 do tamanho**. O factual fica no acaso para todos: destilação transfere **como responder**, não **fato local**.

Q5: RAG entrega o que falta, o fato




Três métricas independentes concordam:

- MCQ: 0,25 para **0,875** (notebook 02)
- acerto factual: **0** para **0,433**
- LLM-juiz (0 a 5): 1,83 para **3,30**

O zero sem RAG é também a prova de ausência de contaminação: o fato local não estava decorado.

Q5: onde o RAG ainda falha



Com RAG a distribuição vira **bimodal**: 0 ou 5.

- recuperou o documento certo: resposta nota 5
- o *retriever* falhou: resposta zero

O gargalo passa a ser o **recall da recuperação**, não o modelo gerador.


Q6: segurança sem treinar nada

Moderação multi-camada: entrada, filtros, LLM e máscara de PII na saída, nessa ordem.

Filtro	Acertos	Taxa
Bloqueio de conteúdo perigoso	18/20	0,90
Deteção de injeção/jailbreak	7/7	1,00
Escopo (dentro e fora do domínio)	8/8	1,00
Máscara de PII (CPF, e-mail, telefone)	6/6	1,00
Proteção geral	39/41	0,951

Os 2 escapes são paráfrases sem as palavras-chave: limite conhecido de filtros por regra (em produção, um classificador como Llama Guard).

Todos os modelos, o mesmo benchmark, IC 95%



- todos **bem acima do acaso** (0,25)
- os intervalos **se sobrepõem**: diferenças pequenas são tendência, não fato estatístico
- 4B+SFT abaixo do 4B base sugere o custo da especialização

Síntese: cada técnica resolve uma coisa

	Resultado	Leitura
Pré-treino	perplexidade de 7,05 para 3,77	fluência, sem esquecer
SFT/QLoRA	atribuição de 0,00 para 0,56	tarefa específica
Destilação	90% do professor com 1/7	compressão
RAG	factual de 0 para 0,433	fato verificável
Guardrails	proteção 0,951	segurança externa

**Fluência e formato vêm de adaptar o modelo;
fatos vêm da recuperação; segurança vem de camadas externas.**

- **Benchmarks pequenos** (dezenas de itens): IC 95% largos; reportamos incerteza em vez de superinterpretar
- **LLM-juiz da mesma família** do gerador (Qwen3-4B); mitigado por três métricas concordantes
- **RAG open-book**: o índice garante o documento-fonte; mede o limite superior, não recall em corpus aberto
- **Treinos enxutos** (T4 grátis, poucos passos): demonstração honesta, não estado da arte

o modelo que “soava” certo tirava zero em fato;
medir bem importa tanto quanto treinar bem

0 $\Rightarrow$ 0,433

acerto factual com RAG, a técnica certa para o problema certo

Repositório: github.com/heitor-am/llm-adaptation-lab

Adapters: Hugging Face, usuário heitor-am

Perguntas?